



Санкт-Петербургский государственный университет

Кафедра системного программирования

Улучшение методов дедупликации SVC

Никитин Артём Денисович, группа 24Б44


Научный руководитель: к.ф.-м.н. В.И. Гориховский, доцент кафедры системного программирования

Консультант: А.С. Дмитриевцев


Санкт-Петербург

2025

Дедупликация



Визуализация идеи Content Define Chunking (CDC)



Цели и задачи

- **Цель:** улучшить методы дедупликации SBC, а также создать механизмы их анализа в файловой системе ChunkFS
- **Задачи:**
 - Реализовать Zdelta, Xdelta, Ddelta и Edelta для интеграции в ChunkFS — файловую систему для бенчмаркинга алгоритмов дедупликации
 - Экспериментально оценить зависимость коэффициента дедупликации от CDC для различных дельта-кодировщиков
 - Добавить функциональность сбора метрик на этапе кластеризации для отладки и анализа работы SBC-алгоритма


Этапы SBC алгоритма


- Разбиение входных данных на чанки
- Вычисление хэш-функции для чанков
- Кластеризация чанков
- Дельта-кодирование схожих чанков



Similarity Based Chunking (SBC)

Визуализация идеи SBC






Ddelta

[2] Wen Xia, Hong Jiang, Dan Feng, Lei Tian, Min Fu, and Yukun Zhou. Ddelta: A deduplication-inspired fast delta compression approach. Performance Evaluation, 79:258–272, 2014.


[3] Wen Xia, Chunguang Li, Hong Jiang, Dan Feng, Yu Hua, Leihua Qin, and Yucheng Zhang. Edelta: A word-enlarging based fast delta compression approach. In the 7th USENIX conference on Hot Topics in Storage and File Systems (HotStorage'15), pages 1–5, Santa Clara, CA, 2015. USENIX Association.

Скользящее окно (4 байта)



Вычисляется 7 отпечатков


(б) CDC разбиение





Вычисляется 4 отпечатка

(а) Разбиваем на фрагменты при помощи скользящего окна по байтам

Edelta





Указатели:

Основной


Вспомогательный

Целевой

[Флаг: LITERAL | Байт: 0x41]


[Флаг: COPY | Указатель | Направление | Длина | Смещение]

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




OS: Ubuntu 24.04.2 LTS x86_64; **CPU:** Intel i5-10300H (8) @ 4.500GHz; **RAM:** 16 Гб;

Результаты экспериментального исследования




Кластеризация



1. Общий размер кластера (количество вершин)
2. Количество кластеров
3. Количество вершин в каждом кластере
4. Расстояние между вершинами в кластере
5. Расстояние между кластерами (между родительскими вершинами)

Предварительные результаты

Зависимость коэффициента дедупликации от диапазона для поиска целевых вершин
FastChunker



Результаты

- Реализованы алгоритмы xdelta, ddelta, zdelta и edelta для SBC скраббер
- Добавлена возможность собирать статистику на этапе кластеризации SBC алгоритма
- Установлена зависимость коэффициента дедупликации от CDC для различных дельта-кодировщиков

Clustering measurements in ChunkFS: <https://github.com/Piletskii-Oleg/chunkfs/pull/9>

Clustering measurements in SBC scrubber: https://github.com/maxscherbakov/sbc_algorithm/pull/13

Xdelta - https://github.com/maxscherbakov/sbc_algorithm/pull/9

Zdelta - https://github.com/maxscherbakov/sbc_algorithm/pull/10

Ddelta/Edelta - https://github.com/maxscherbakov/sbc_algorithm/pull/12