

Улучшение методов дедупликации SBC

Никитин Артём Денисович

Группа: 24.Б44-мм

Кафедра: Системное программирование

Научный руководитель: Гориховский Вячеслав Игоревич

Консультант: Дмитриевцев Алексей Сергеевич

Номер семестра практики: 3

1. Постановка задачи

Работа в интересах компании YADRO в рамках проекта ChunkFS. **Целью работы является улучшить методы дедупликации SBC, а также создать механизмы их анализа в файловой системе ChunkFS**

Дедупликация данных — это алгоритм сжатия, нацеленный на выявление идентичных блоков данных и их удаление.

Similarity Based Chunking (SBC) — метод дедупликации, при котором данные сначала разбиваются на блоки (чанки), а затем с помощью хеширования определяется степень их схожести. Похожие чанки объединяются в кластеры. Сжатие обеспечивается алгоритмами дельта-кодирования, такими как Zdelta, Xdelta, Gdelta, Ddelta и Edelta. Эти кодировщики итерируются по кластеру, оставляя в нём только один родительский чанк и инструкции для восстановления остальных похожих чанков.

Результаты работы необходимы для качественного бенчмаркинга SBC-алгоритма. Исследования проводятся в целях увеличения коэффициента дедупликации.

2. Описание предлагаемого решения

Xdelta¹ — алгоритм дельта-кодирования использующий скользящее окно для вычисления хеша Adler32.

Gdelta² — использует для хеширования не Adler32, а gear hash. (Было реализовано ранее)

Ddelta³ — алгоритм использующий content define chunking (CDC) для разбиения чанка и вычисления хеша.

Edelta⁴ — оптимизация ddelta, использующая эвристику: если данные в целевом чанке и родительском совпали, то данные находящиеся поблизости тоже совпадут.

Zdelta⁵ — алгоритм использующий три указателя для умного вычисления смещения сору инструкций.

Алгоритмы интегрированы в ChunkFS — файловую систему для бенчмаркинга алгоритмов дедупликации.

Помимо этих алгоритмов мной была реализована функциональность позволяющая собирать данные о этапе кластеризации SBC-алгоритма.

Ранее существующие решения не интегрированы в файловые системы бенчмаркинга методов дедупликации с открытым и исходным кодом.

Реализация решения осуществлялась с использованием языка Rust и файловой системы ChunkFS.

3. Эксперименты

Исследовательский вопрос: как коэффициент дедупликации для каждого кодировщика зависит от CDC?

Метрики: <https://docs.google.com/spreadsheets/d/15200nph2a-DgmPHKsB0gL2AIYR7s2dLHWC19rbjdrLo/edit?hl=ru&gid=0#gid=0>

Вывод: Наилучший коэффициент дедупликации для всех кодировщиков был получен на Ultra CDC (прирост около 10 процентов). Ранее при анализе других кодировщиков были получены схожие результаты⁶. Можно сделать предположение что Ultra это самый подходящий CDC для работы с SBC. Для всех CDC Xdelta даёт наибольший коэффициент дедупликации.

4. Заключение

В ходе выполнения работы получены следующие **результаты:**

- Реализованы алгоритмы xdelta, ddelta, zdelta и edelta для SBC scrubber
- Добавлена возможность собирать статистику на этапе кластеризации SBC алгоритма
- Установлена зависимость коэффициента дедупликации от CDC для различных дельта-кодировщиков

Ссылки на пуллреквесты:

- Clustering measurements in ChunkFS: <https://github.com/Piletskii-0leg/chunkfs/pull/9>
- Clustering measurements in SBC scrubber: https://github.com/maxscherbakov/sbc_algorithm/pull/13
- Xdelta: https://github.com/maxscherbakov/sbc_algorithm/pull/9
- Ddelta/Edelta: https://github.com/maxscherbakov/sbc_algorithm/pull/12
- Zdelta: https://github.com/maxscherbakov/sbc_algorithm/pull/10

Техническая документация: https://github.com/ArtemNikitIn/sbc_algorithm/blob/main/src/encoder/EncoderDocument.md

В будущем планируется исследовать взаимосвязь коэффициента дедупликации и формы кластера на различных датасетах.

¹Dimitre Trendafilov, Nasir Memon, and Torsten Suel. Zdelta: An efficient delta compression tool. Technical report, Department of Computer and Information Science at Polytechnic University, 2002.

²H. Tan, Z. Zhang, X. Zou, Q. Liao, and W. Xia, "Exploring the potential of fast delta encoding: Marching to a higher compression ratio" in Proc. IEEE Conf., 2020.

³Wen Xia, Hong Jiang, Dan Feng, Lei Tian, Min Fu, and Yukun Zhou. Ddelta: A deduplication-inspired fast delta compression approach. Performance Evaluation, 79:258–272, 2014.

⁴Wen Xia, Chunguang Li, Hong Jiang, Dan Feng, Yu Hua, Leihua Qin, and Yucheng Zhang. Edelta: A word-enlarging based fast delta compression approach. In the 7th USENIX conference on Hot Topics in Storage and File Systems (HotStorage'15), pages 1–5, Santa Clara, CA, 2015. USENIX Association.

⁵Haoliang Tan, Zhiyuan Zhang, Xiangyu Zou, Qing Liao, Wen Xia. Exploring the Potential of Fast Delta Encoding: Marching to a Higher Compression Ratio. — 2021.

⁶Щербаков М.А. Гориховский В.И. Повышение качества дедупликации с помощью Similarity Based Chunking 2025. — <https://www.elibrary.ru/item.asp?id=81439119&pff=1>